16 - Prática: Redes Neurais Convolucionais 1 (Deep Learning (II)
Ronny Gabryel Colatino de Souza

1 - Introdução

O objetivo desse card foi entender como as redes neurais convolucionais funcionam e por que elas são tão usadas quando o assunto é imagem o vídeo cobriu desde o conceito de como uma imagem é representada no computador até as etapas que a rede passa antes de chegar na parte tradicional de classificação

---

2 - Desenvolvimento

Como o computador enxerga uma imagem

Antes de entender a rede em si o card começa explicando como uma imagem é representada no computador e isso foi bem interessante de ver uma imagem nada mais é do que uma matriz onde cada posição é um pixel com valor de 0 a 255 onde 0 é o mais escuro e 255 o mais claro numa escala de cinza isso já basta mas quando temos imagens coloridas entram as 3 camadas RGB que são vermelho verde e azul cada uma com seus próprios valores de 0 a 255 o que no final gera todas as cores que a gente conhece

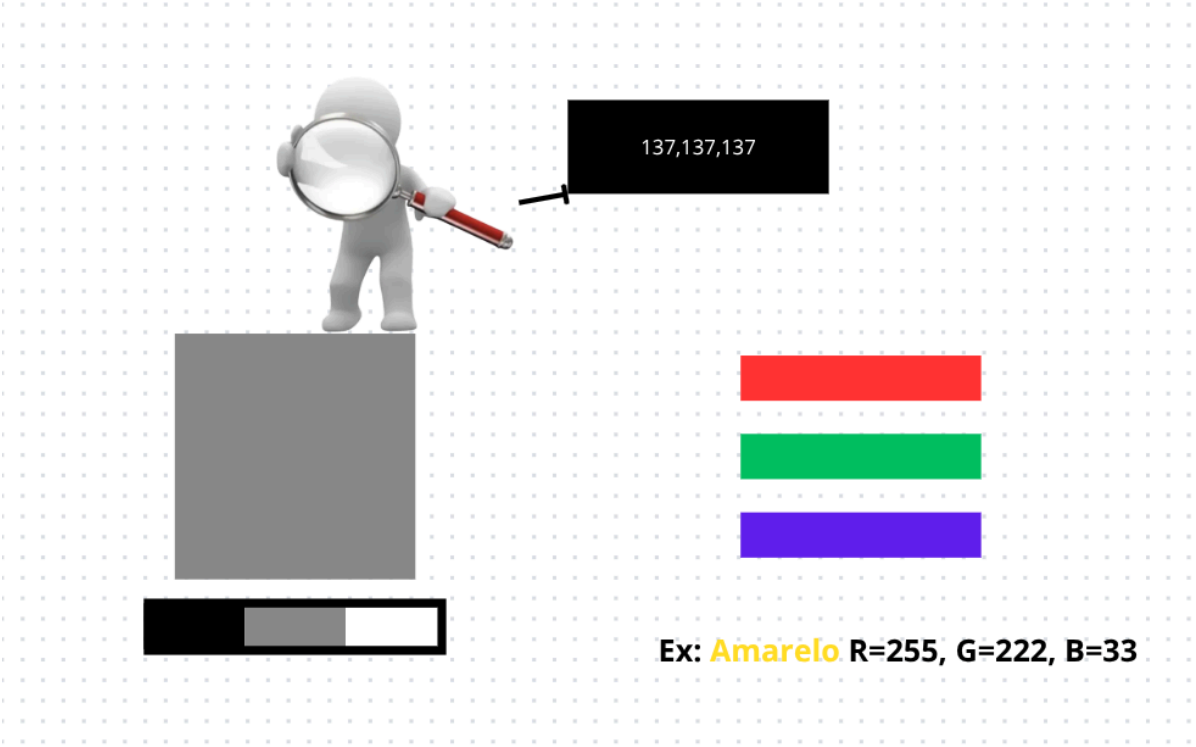

A parte convolucional da rede

A grande diferença das redes neurais convolucionais em relação às redes tradicionais é que antes de jogar os dados na rede de verdade elas passam por etapas de transformação da imagem a primeira delas é a convolução que é basicamente aplicar um detector de características na imagem esse detector é uma matriz pequena normalmente 3x3 que percorre toda a imagem multiplicando e somando os valores e gerando como resultado um mapa de características menor do que a imagem original mas que preserva as principais informações tipo bordas cores e outros padrões importantes

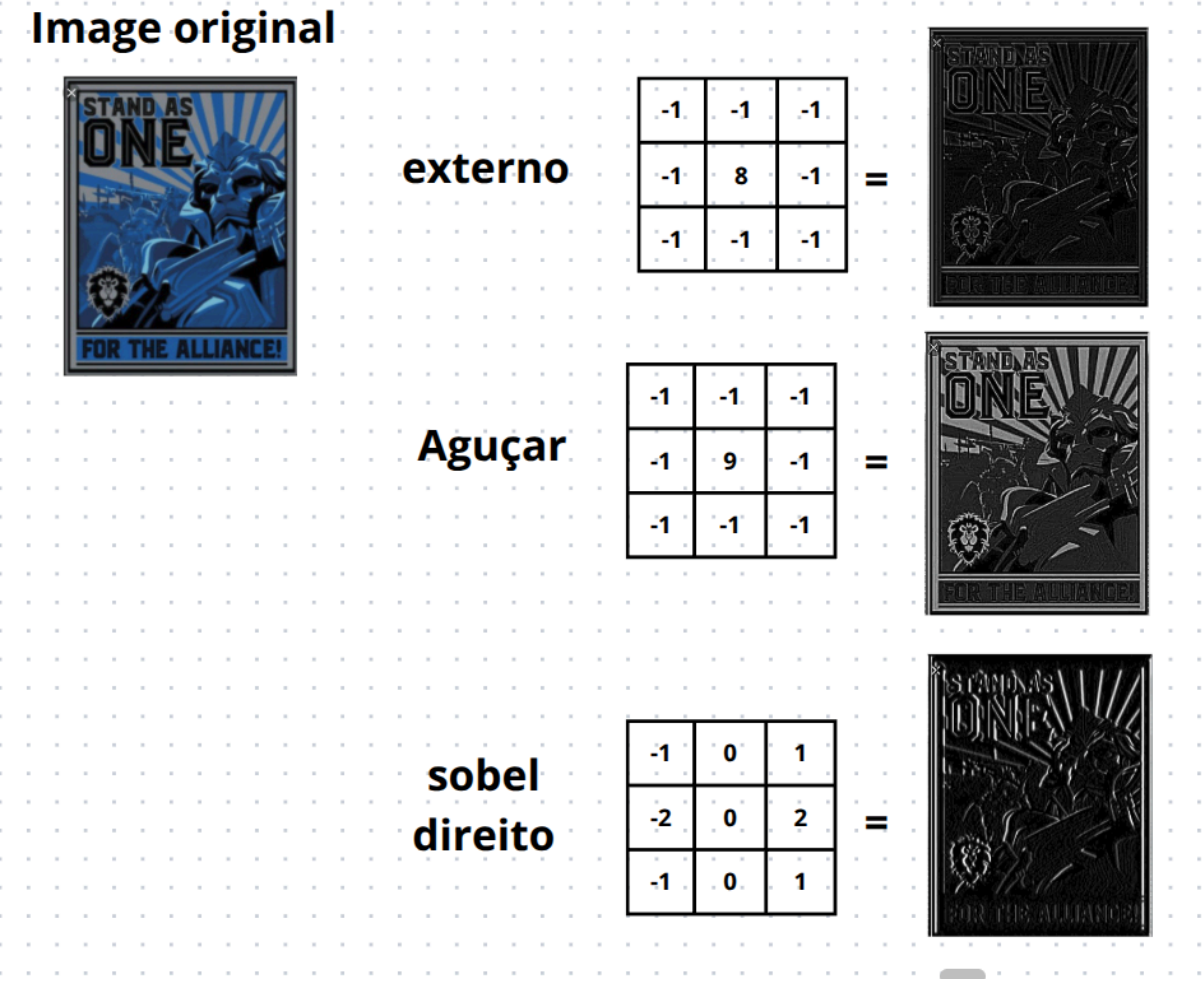

Uma coisa que achei interessante é que existem vários tipos de detectores de características cada um servindo pra uma coisa diferente tipo deixar a imagem mais nítida adicionar blur identificar bordas entre outros e tudo isso acontece de forma automática dentro do código o que é bem poderoso

Pooling

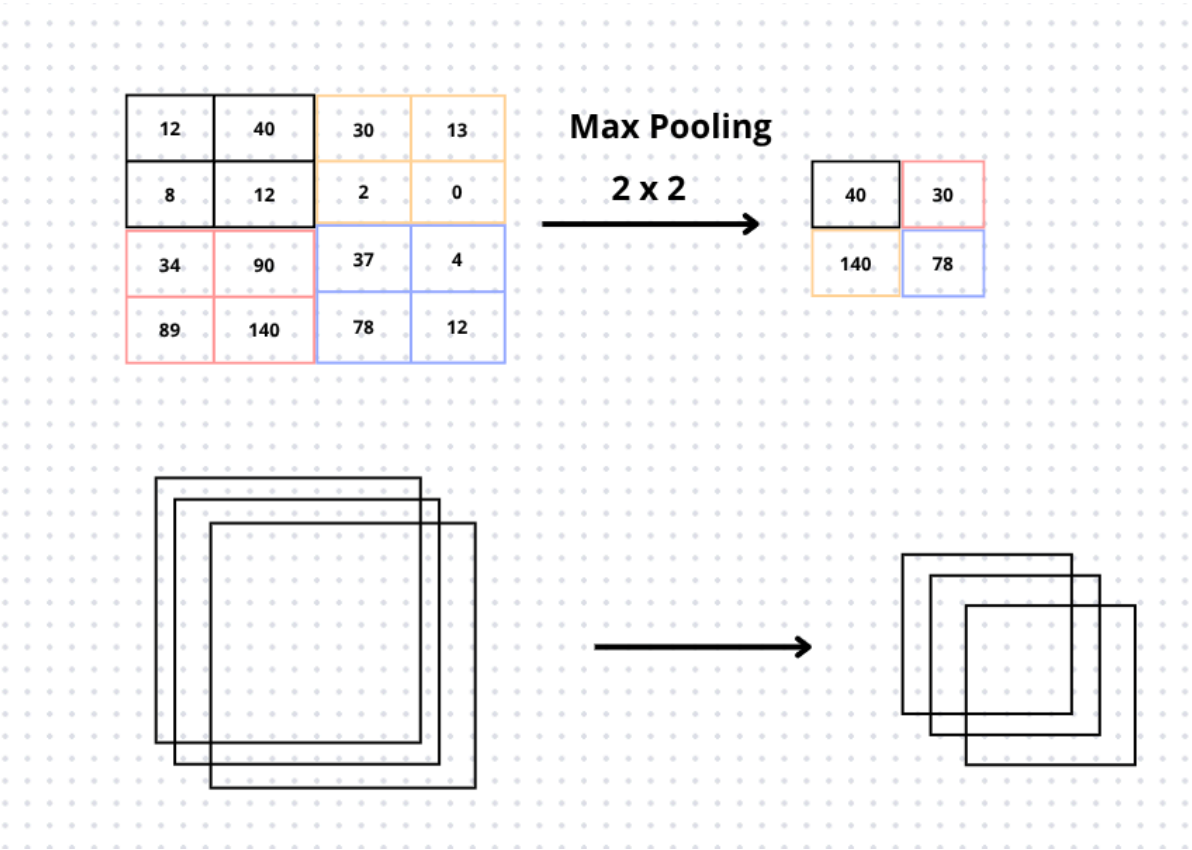

Depois da convolução os mapas de características passam pela etapa de pooling que serve pra reduzir ainda mais o tamanho da matriz a técnica mais comum é o Max Pooling onde você pega uma região do mapa e guarda só o maior valor isso reduz a complexidade da imagem e ainda ajuda a evitar um problema bem comum que é o overfitting que é quando o modelo decora os dados de treino ao invés de aprender de verdade existe também o Average Pooling que pega a média ao invés do maior valor mas não é a opção mais usada

Flattening

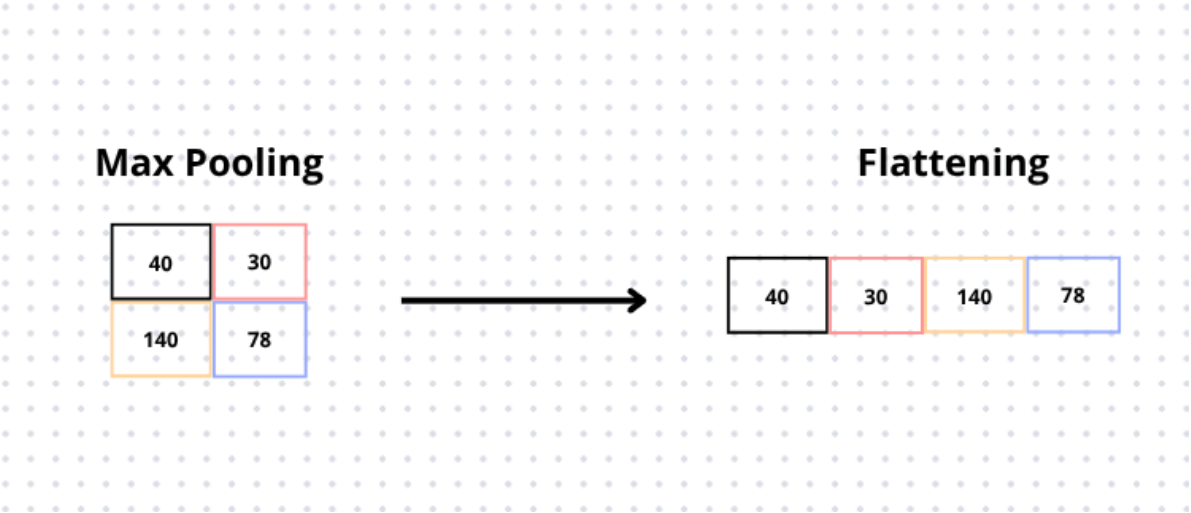

A última etapa antes de chegar na rede neural tradicional é o flattening que é bem simples no conceito mas essencial no processo basicamente todas as matrizes que vieram do pooling são transformadas em vetores um único array com todos os valores e é esse array que vai entrar na camada de entrada da rede neural como nos modelos que a gente já tinha visto antes passando pelas camadas ocultas com os pesos sendo ajustados até chegar na camada de saída com a classificação final

O processo completo

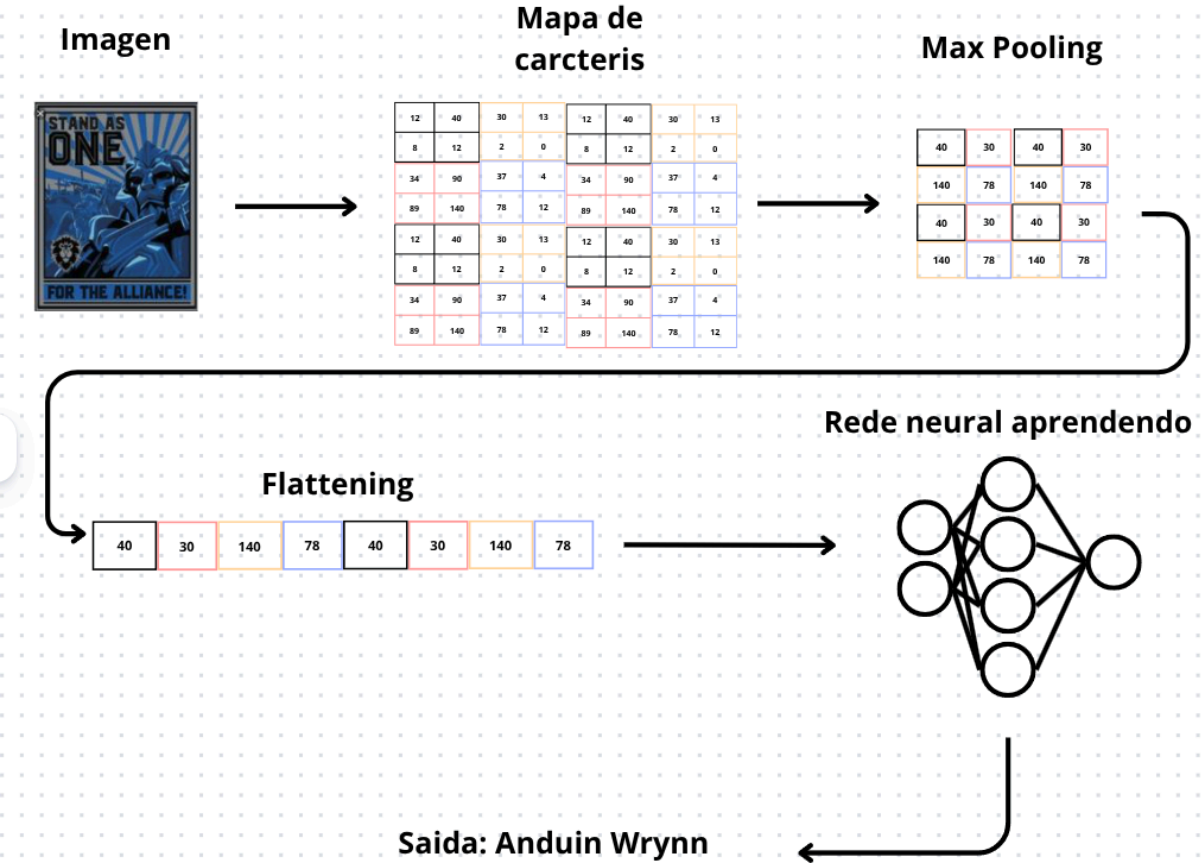

Juntando tudo o processo de uma rede neural convolucional segue esse fluxo a imagem entra como uma matriz de pixels passa pelo detector de características gerando os mapas de características depois passa pelo max pooling reduzindo ainda mais o tamanho em seguida vem o flattening transformando tudo em vetor e por fim esse vetor alimenta a rede neural tradicional que entrega o resultado final tipo identificar se uma imagem é um gato ou um cachorro por exemplo é um processo bem mais elaborado do que uma rede simples mas faz muito sentido quando você entende que imagens têm muito mais informação do que dados

---

3 - Conclusão

Esse card foi bem esclarecedor sobre como lidar com imagens usando Deep Learning o mais importante que ficou foi entender que as redes convolucionais não

jogam a imagem direto na rede elas primeiro extraem as características mais relevantes reduzem a complexidade e aí sim passam pra classificação isso é o que torna esse tipo de rede tão eficiente pra imagens e tão usado em aplicações reais

---

4 - Referências

Vídeos do card: Deep Learning com Python de A a Z – Seções 8 à 10