17 - Prática: Redes Neurais Convolucionais 2 (Deep Learning) (II)

Ronny Gabryel Colatino de Souza

1 - Introdução

O objetivo desse card foi aprofundar o que já tinha sido visto sobre redes neurais convolucionais, dessa vez indo além da estrutura básica e explorando técnicas mais específicas como os modos de convolução, stride, padding, funções de perda e como usar CNNs até em texto, o que foi bem interessante de ver

---

2 - Desenvolvimento

O que é Convolução

A convolução é basicamente um modificador de imagem, ela pega a imagem de entrada, aplica um filtro em cima dela fazendo multiplicações e somas, e gera uma imagem de saída com as características que aquele filtro foi feito pra extrair o que muda de uma CNN pra outra é justamente o filtro que ela usa, por exemplo um filtro gaussiano vai desfocar a imagem e um filtro de detecção de bordas vai deixar só as bordas visíveis

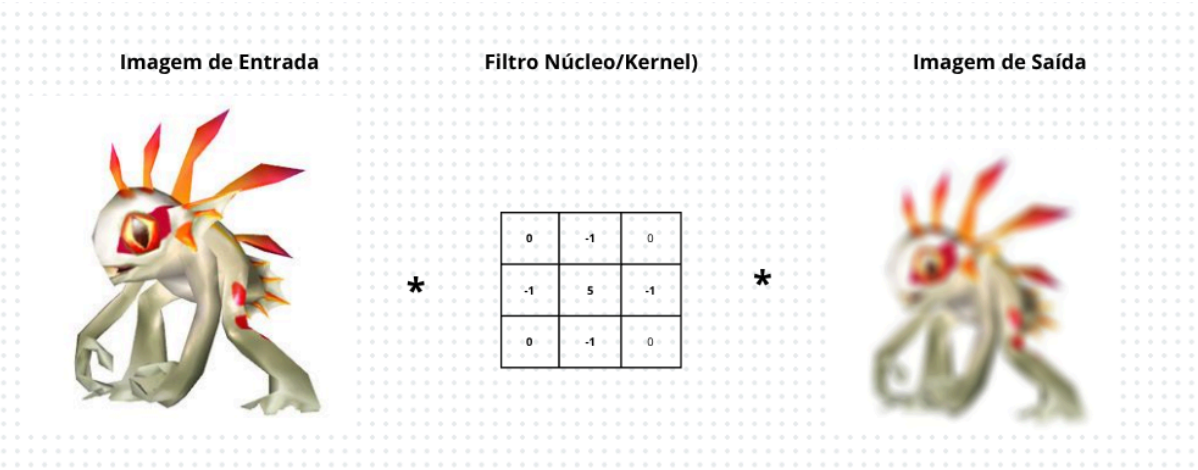

O cálculo segue sempre a mesma lógica o filtro percorre a imagem da esquerda pra direita e de cima pra baixo e o tamanho do output sempre vai ser N(imagem) - k(filtro) + 1, o que significa que a imagem de saída vai ser menor do que a de entrada

Modos de Convolução

X filtro

-1	0	+1
-2	0	+2
-1	0	+1

Y Filtro

+1	+2	+1
0	0	0
-1	-2	-1

Esse card trouxe os modos de convolução, que basicamente controlam como o filtro se comporta nas bordas da imagem o modo validação não adiciona nada ao redor da imagem então a saída fica menor, o modo same adiciona zeros ao redor usando uma técnica chamada padding pra que a saída tenha o mesmo tamanho da entrada, e o modo full vai além das bordas da imagem gerando uma saída ainda maior

CNN Architecture

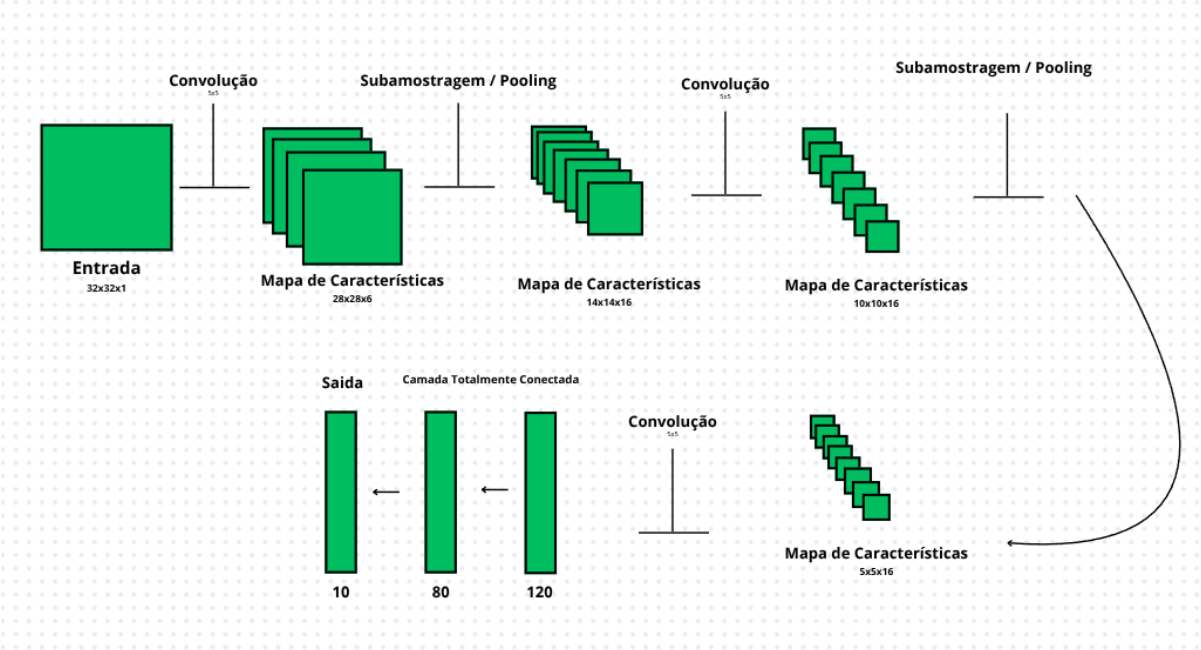

A arquitetura de uma CNN segue um fluxo bem definido onde a imagem passa por camadas de convolução que extraem as características, depois por camadas de pooling que reduzem o tamanho, e no final pelo flattening que

transforma tudo em um vetor pra entrar na rede neural tradicional algo importante que apareceu aqui é que todas as imagens passadas pra rede precisam ter o mesmo tamanho, senão o vetor gerado no final vai ter um tamanho diferente do esperado e a rede não funciona

Stride e Padding

Além dos modos de convolução o card também falou sobre o stride, que é uma alternativa ao pooling e funciona de um jeito bem inteligente, em vez de percorrer a imagem pixel por pixel ele pula alguns pixels de cada vez e isso funciona bem porque numa imagem é muito provável que pixels vizinhos tenham cores parecidas então não faz tanta diferença olhar todos eles um por um o padding pode ser usado junto com o stride pra adicionar zeros ao redor da imagem, o que ajuda a preservar as informações das bordas que normalmente acabam sendo perdidas durante a convolução.

Batch Normalization

O Batch Normalization é uma camada que pode ser adicionada na CNN pra normalizar os dados durante o treinamento, ele calcula a média e o desvio padrão de cada batch e faz a normalização com base nesses valores, o que ajuda a estabilizar o treino e em alguns casos evita o overfitting

Data Augmentation

O Data Augmentation é a solução pra quando você não tem imagens suficientes pra treinar o modelo, ele gera variações das imagens originais em tempo real aplicando rotações, zoom, inversões e outras transformações, o que aumenta a diversidade dos dados sem precisar coletar mais nada vale lembrar que quanto mais tipos de transformação você define, mais processamento e memória vão ser usados

Embeddings e CNN para Texto

A parte que achei mais diferente foi ver que dá pra usar CNN em texto também e não só em imagem o One-Hot Encoding que já tinha sido visto antes não funciona bem pra isso porque a distância entre qualquer par de palavras acaba sendo sempre a mesma, o que não faz sentido já que palavras têm relações diferentes entre si a solução é o Embedding, que converte as palavras em números inteiros e depois mapeia esses números em vetores, onde a proximidade entre os vetores indica o quanto as palavras são parecidas, aí sim a rede consegue encontrar relações geométricas entre elas

Funções de Perda

As funções de perda são usadas pra medir o erro do modelo durante o treinamento. O MSE é muito usado em regressão e calcula a média do

quadrado da diferença entre o valor real e o previsto, usar o quadrado garante que os valores sejam sempre positivos e pune erros maiores de forma mais forte já a Binary Cross-Entropy é usada pra classificação binária e a Categorical Cross-Entropy é usada quando tem mais de duas classes possíveis

Gradient Descent

O Gradient Descent é o método usado pra ajustar os pesos da rede, ele calcula a derivada parcial do erro em relação a cada peso e move esses pesos na direção que minimiza o erro existe também o Stochastic Gradient Descent que faz esse ajuste de forma mais rápida usando amostras menores dos dados em vez do conjunto todo de uma vez

Momentum e Adam

O Momentum foi introduzido pra melhorar o processo de descida do gradiente, ele funciona como uma aceleração que ajuda a rede a passar por regiões com gradientes muito pequenos sem travar e chegar na solução mais rápido. Já o Adam combina o Momentum com o RMSProp e acaba sendo um dos otimizadores mais usados na prática porque ele ajusta a taxa de aprendizado de forma adaptativa pra cada peso, tornando o treinamento bem mais eficiente no geral

Técnica Parâmetro	Modo de funcionamento	Quando Usar
Padding	Adiciona bordas de zeros na imagem	Mantém o tamanho da saída igual ao da entrada evitando perda de dados nas bordas
Stride	Define quantos pixels o filtro pula por vez	Reduz o tamanho da imagem final e o custo de processamento da rede
Data Augmentation	Cria variações giros, zoom das imagens	Resolve o problema de ter poucos dados ensinando a rede a ser mais flexível
Otimizador Adam	Ajusta a taxa de aprendizado para cada peso	É mais eficiente porque combina velocidade Momentum com estabilidade

---

3 - Conclusão

Esse card foi bem mais denso que o anterior mas valeu muito, deu pra entender que além da estrutura básica de convolução, pooling e flattening existem várias técnicas por baixo que fazem a rede funcionar melhor em situações diferentes, desde controlar como o filtro percorre a imagem até lidar com pouca quantidade de dados ou trabalhar com texto pude testar muita coisa por conta propria com as documentações que encontrei

---

4 - Referências

Vídeo da pasta -Deep Learning: Convolutional Neural Networks in Python- da sessão 5 a 11

Documentações usadas:
PyTorch - Conv2d (documentação oficial):
https://docs.pytorch.org/docs/stable/generated/torch.nn.Conv2d.html

Tutorial completo de CNN com PyTorch (DataCamp):
https://www.datacamp.com/tutorial/pytorch-cnn-tutorial