19 - Prática: Pipelines de Dados II - Airflow (III)
Ronny Gabryel Colatino de Souza

1 - Introdução

O objetivo desse card foi entender como o Apache Airflow funciona de forma mais avançada cobrindo desde os diferentes tipos de executores até o conceitos mais complexos

---

2 - Desenvolvimento

Executores do Airflow

A primeira parte do card foi sobre os diferentes executores disponiveis no airflow e isso foi bem importante pra entender como executar apenas uma das DAGs o SequentialExecutor é o mais entender como escalar o processamento tarefa por vez o que o torna útil so pra aprendizado e teste básicos por que ele usa o SQLite que não suporta acessos concorrentes já o LocalExecutor é mais robusto e permite executar várias tarefas em paralelo usando múltiplos processos na mesma máquina mas pra isso precisa de um banco como o PostgreSQL que suporta operações concorrentes

Executor	Banco de Dados	Capacidade	Uso Recomendado
Sequential	SQLite	1 tarefa por vez	Aprendizado e testes rápidos
Local	PostgreSQL/MySQL	Múltiplas tarefas	Produção de pequeno porte e DAGs complexas
Celery	PostgreSQL/MySQL	Distribuído em vários Workers	Ambientes de produção escaláveis e resilientes
Kubernetes	PostgreSQL	1 Pod por tarefa	Isolamento total e alta escalabilidade cloud.

Uma coisa que achei bem interesssante foi ver os parâmetros que podem ser configurados como o parallelism que controla quantas tarefas podem rodar ao mesmo tempo globalmente o dag_concurrency que limita quantas tarefas de uma mesma DAG rodam em paralelo e o worker_concurrency que define quantas tarefas cada worker pode pegar de uma vez isso tudo ficou muito mais claro quando vi na

prática a diferença entre rodar com parallelism igual a 1 e parallelism igual a 3 onde as tarefas claramente terminaram mais rápido no segundo caso

CeleryExecutor e KubernetesExecutor

O CeleryExecutor foi a parte que mais me chamou atenção porque ele permite distribuir as tarefas entre múltiplos workers que podem estar em maquinas diferentes o que torna o sistema muito mais tolerante a falhas porque se um worker travao Airflow passa as tarefas pra outro que estiver disponível e isso é muito importante em ambientes de produção onde você não pode ter o pipeline parando por causa de uma falha em uma maquina só

Já o KunermetesExecutor vai além disso porque ele cria um pod separado no Kubernetes pra cada tarefas o que garante isolamento total entre as execuções e permite escalar de forma muito mais eficiente conforme a demanda aparecem alguns termos como Pod ReplicaSet Deployment e PVC que descrevem como o Kubernetes organiza e gerencia esses recursos de forma automática

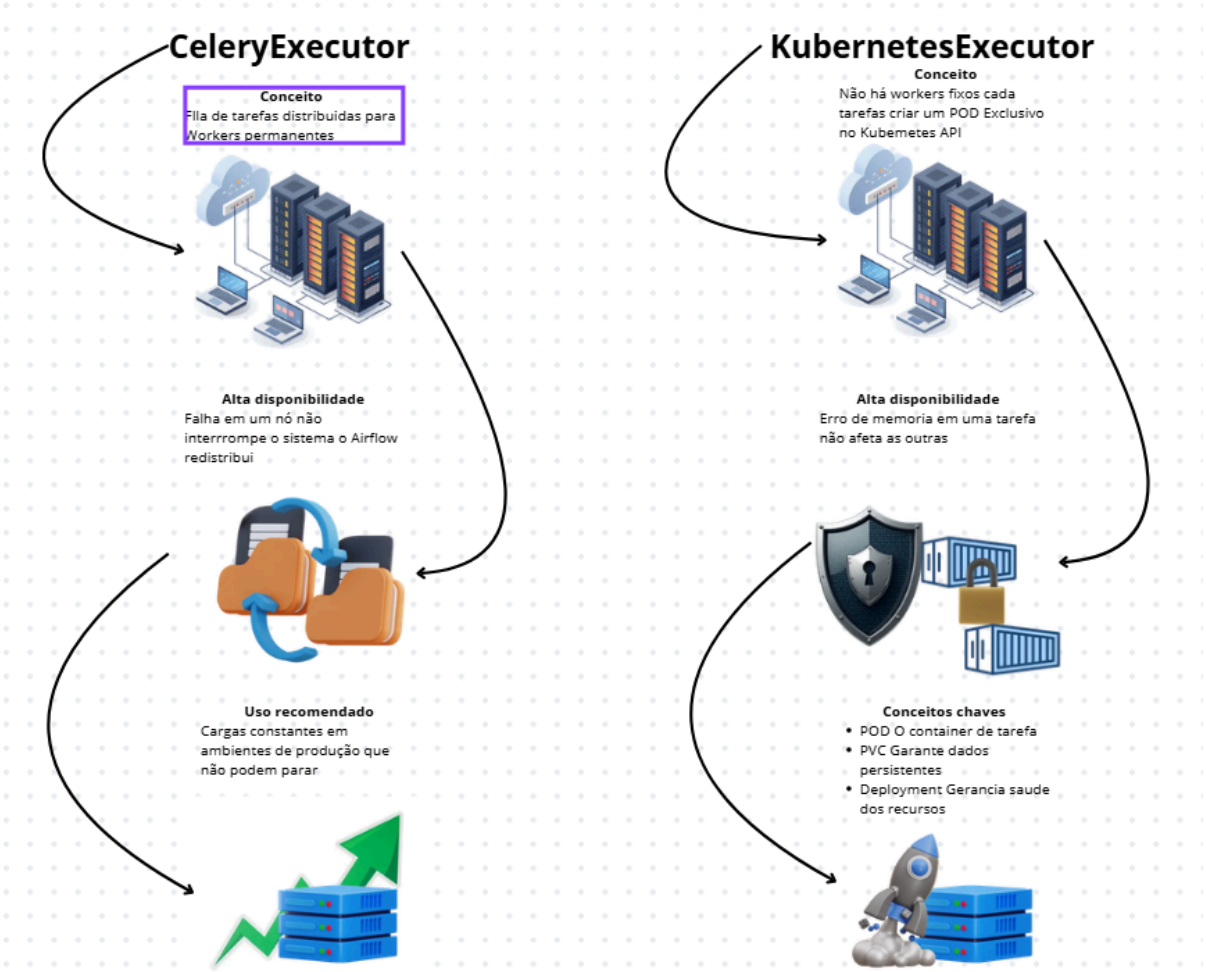

Conceitos Avançados de DAGs

A parte de conceitos acançados foi a que eu achei mais completa porque mostrou formas de deixar as DAGs mais organizadas e inteligentes as SubDAGs por exemplo permitem agrupar tarefas repetidas dentro de uma DAG maior o que deixa o fluxo muito mais limpo de entender visualmente dentro de uma DAG maior o que deixa o fluxo muito mais limpo de entender visualmente o Branching foi outro conceito bem útil que permite a DAG tomar decisões automáticas sobre qual caminhos seguir dependendo do resultado de uma tarefa como por exemplo verificar qual API está disponível a só ai decidir qual usar

O XCom foi algo eu q eu conhecia e achei muito util por que é o mecanismo do Airflow pra passar informações entre tarefas das mesma DAG usando xcom_push pra enviar e xcom_pull para recuperar esses dados algo que é essencial quando uma tarefa depende do resultado de outra também vi o TriggerDagRunOperator que permite uma DAG dispara a execução de outra e ExternalTaskSensor que fica monitorando o estado de uma tarefa em outra DAG pra so então executar o que precisa

Monitoramento e Segurança

A parte de monitoramento mostrou como acompanhar a execução das DAGs e dos worjers usando diferentes níveis de log como INFO WARNING ERROR DEBUG e CRITICAL onde cada nível mostra um grau diferente de detalhe sobre o que está acontecendo no sistema além disso foi mostrado como usar o ELK Stack que combina Elasticsearch Logstash e Kibana para coletar processar e visualizar os logs de forma bem organizada e o TIG Stack com Telegraf InfluxDB e Grafana para monitorar métricas de desempenho como tempo de execução das tarefas e número de falhas

A parte de segurança foi bem esclarecedora porque mostrou que sem nenhuma configuração adicional é possivel acessr o banco de dados do AIrflow e ver senhas e informações sensíveis completamente sem filtro a solução para isso é usar a Fernet Key que cirptografa esses dados no banco e o modo seguro que esonde variaveis foi mostrado como adicionar autenticação na UI e filtrar as DAGs por usuário o que é essencial num ambiente com varias pessoas usando a mesma instâncias

---

3 - Conclusão

Este card foi muito bom para reforçar sobre como Aiflow e como ele funciona em ambientes mais sérios e complexos o que mais ficou foi a diferenças entre os executores e como cada um resolve um problema diferente de escala e tolerância a

falha além disso os conceitos de segurança me fizeram perceber que configurar o Airflow corretamente vai muito alem so criar DAGs é preciso pensar em criptografia

---

4 - Referências

Vídeo do card: 19 - Prática: Pipelines de Dados II - Airflow (III) da sessão 5 a 9