21 - Prática: Visão Computacional (III)

Ronny Gabryel Colatino de Souza

1 - Introdução

O objetivo desse card foi se aprofundar nos fundamentos do deep learning e como aplicar redes neurais na prática usando o PyTorch cobrindo desde os conceitos mais básicos como tensores até arquiteturas mais avançadas como as CNNs e os Autoencoders

---

2 - Desenvolvimento

A primeira parte foi sobre os fundamentos do deep learning, e o primeiro conceito apresentado foi o de Tensor, que é basicamente o formato principal de dados usado no PyTorch e que pode representar desde um valor único até matrizes e estruturas com várias dimensões. O que achei interessante é que, com tensores, você consegue fazer operações matemáticas como soma, subtração, multiplicação e divisão da mesma forma que faz com matrizes normais, mas de forma otimizada pra cálculos de aprendizado profundo.

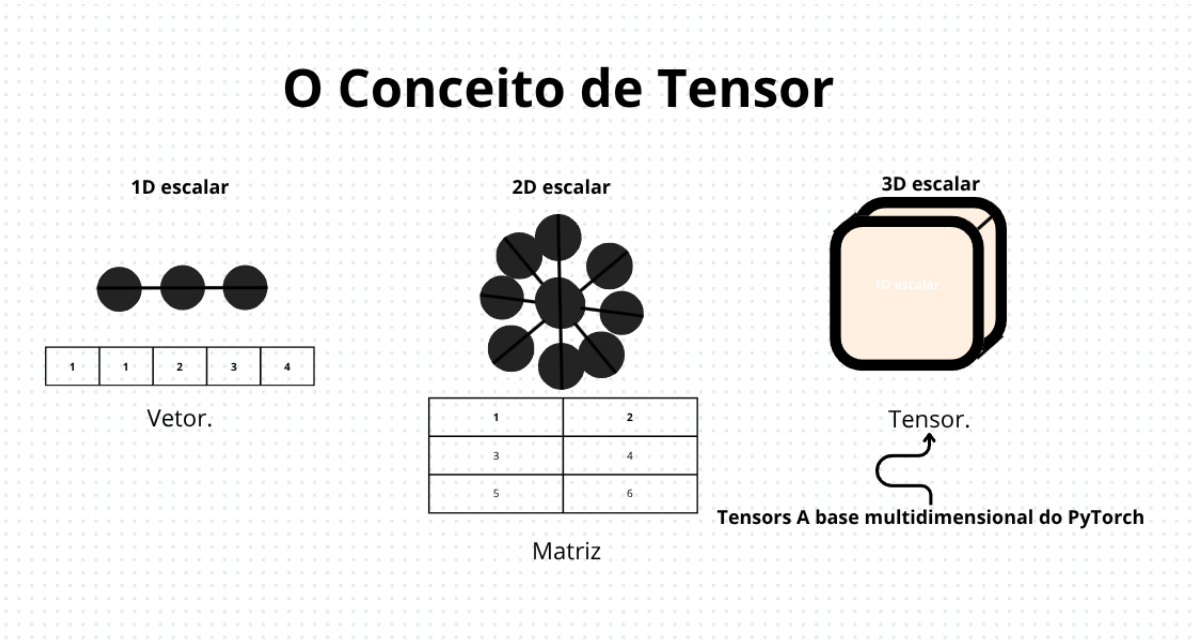

Depois disso, foi apresentado os diferentes tipos de redes neurais que existem, e cada uma tem uma aplicação bem específica. As ANNs são as mais básicas e funcionam bem pra problemas de classificação, regressão e previsão com dados estruturados. Já as RNNs são feitas pra lidar com dados sequenciais, como texto e séries temporais, porque elas conseguem guardar uma memória dos estados anteriores, o que é essencial pra tarefas como tradução automática e análise de sentimentos. E as CNNs são as mais usadas pra imagens e vídeos, porque elas conseguem extrair características espaciais usando camadas de convolução e pooling, o que as torna muito mais eficientes pra esse tipo de dado.

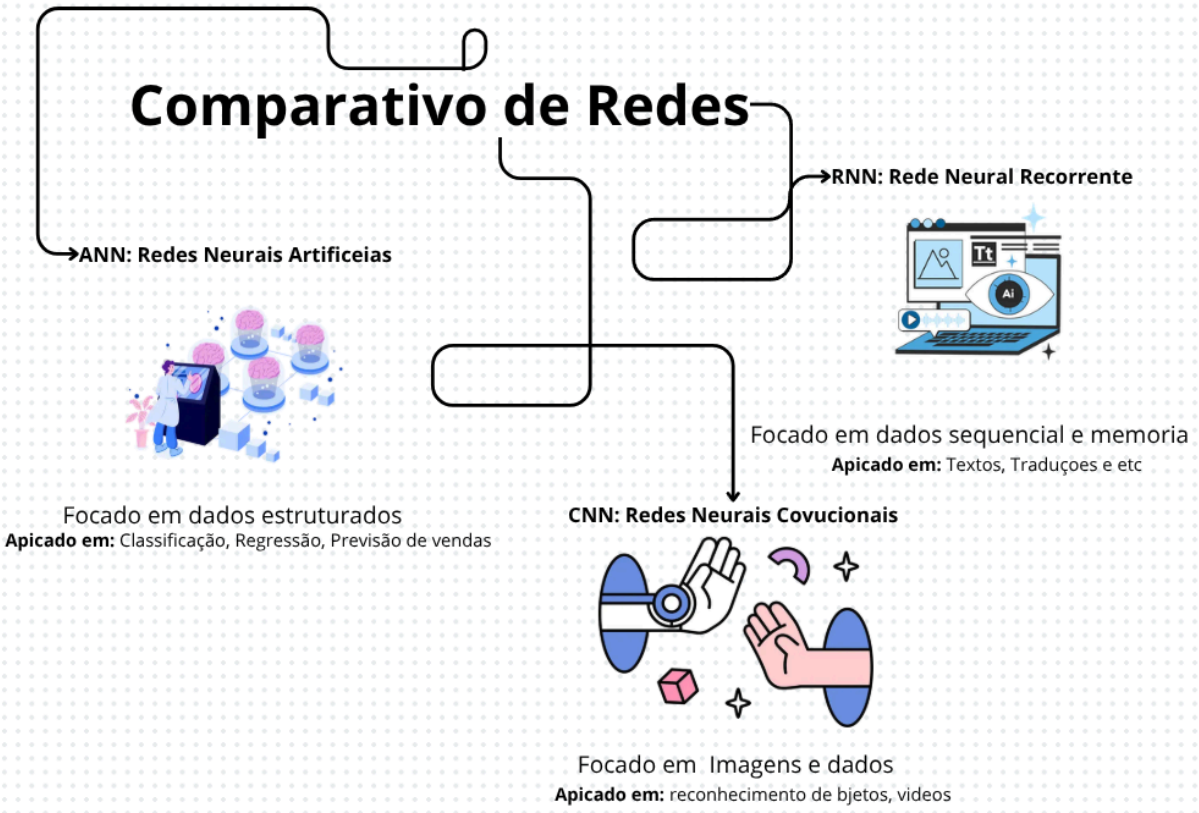

Uma coisa que ficou bem clara na parte prática foi o processo de treinar uma rede neural, porque não é só criar a arquitetura e sair rodando. Você precisa definir uma função de perda, que mede o quanto o modelo está errando, um otimizador, que ajusta os pesos pra minimizar esse erro, e hiperparâmetros, como a taxa de aprendizado, que influenciam diretamente como o modelo aprende. E tudo isso junto determina se o modelo vai convergir bem ou não.

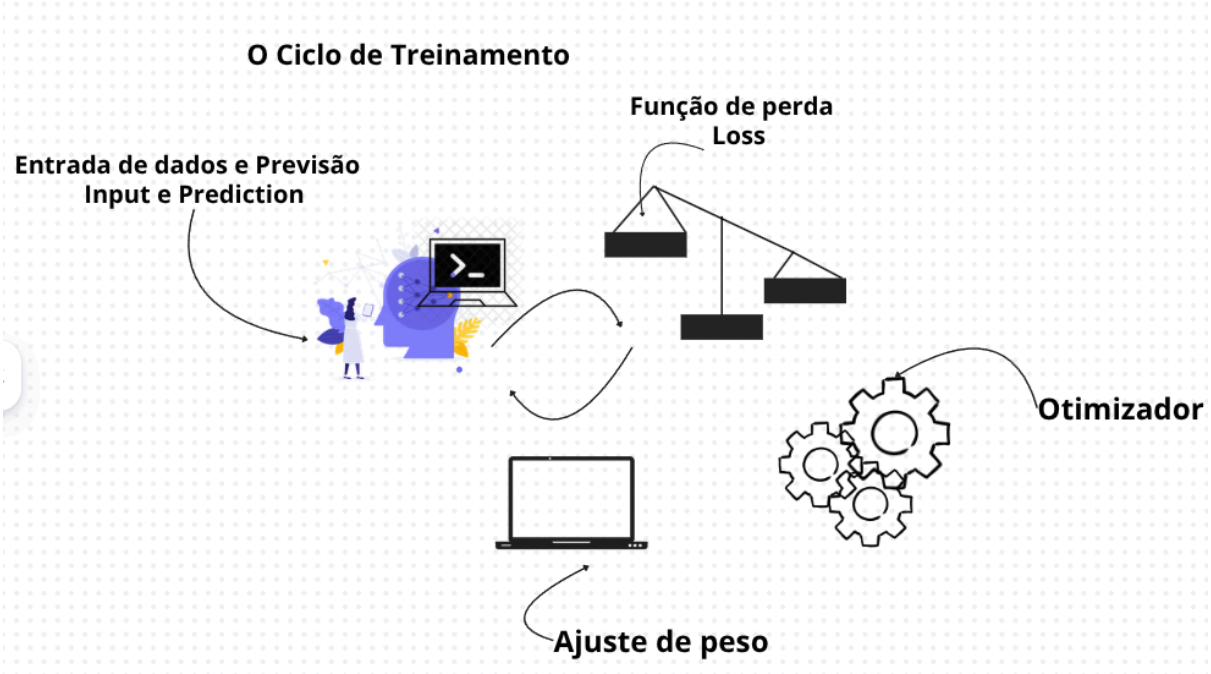

A parte de CNNs foi bem interessante, porque mostrou como o Data Augmentation pode ser usado pra aumentar artificialmente o tamanho do dataset, aplicando transformações nas imagens como deslocamentos e rotações, o que ajuda bastante a melhorar a precisão do modelo, porque ele acaba vendo mais variações dos dados durante o treino e aprende a generalizar melhor.

Outra parte que achei muito interessante foi a dos Autoencoders, que são um tipo de rede neural que aprende a comprimir uma imagem num espaço de dimensão menor, chamado de espaço latente, e depois tenta reconstruir a imagem original a partir disso. E o que me chamou atenção foi o VAE, que vai além disso, porque em vez de aprender um ponto fixo no espaço latente, ele aprende uma distribuição de probabilidade, o que permite gerar novas amostras de dados que se parecem com os dados originais, mas que nunca existiram de verdade.

Na parte de projetos práticos, foi mostrado aplicações bem legais, como colorização automática de imagens em preto e branco usando autoencoders e transferência de estilo, que permite pegar o estilo visual de uma pintura famosa e aplicar no conteúdo de outra imagem usando uma rede VGG19. E o resultado ficou visualmente impressionante, mostrando o quanto essas técnicas já chegaram num nível bem avançado.

---

3 - Conclusão

Esse card foi muito completo porque mostrou tanto a teoria quanto a prática de deep learning aplicado à visão computacional o que mais ficou foi entender as diferenças entre os tipos de redes neurais e quando usar cada uma além de ver na prática que só aumentar a complexidade do modelo não garante um resultado melhor é preciso pensar em dados de qualidade boas estratégias de treinamento e a arquitetura certa pro problema que você quer resolver

---

4 - Referências

Vídeo do card: 20 - Prática: Visão Computacional (III) - Seções 2 a 7