

23 - Prática: Reconhecimento de Emoções com TensorFlow 2.0 e Python (III)


Ronny Gabryel Colatino de Souza

1 - Introdução

O objetivo desse card foi entender como funciona o reconhecimento de emoções em imagens e vídeos usando deep learning e redes neurais convolucionais, cobrindo desde os conceitos teóricos de convolução, pooling e flattening até a aplicação prática com TensorFlow e OpenCV

2 - Desenvolvimento

A primeira parte sobre reconhecimento de emoções funciona de forma geral e o que me chamou atenção logo de cara, foi entender que expressões faciais são uma forma importantíssima de comunicação não verbal e que tem aplicações bem sérias no mundo real como, como monitoramento de motoristas sonolentos em carros semi autônomos ou alunos em aulas EAD, o que mostra que não é só uma curiosidade tecnológica mas algo com impacto real e importante que deve ser visto com atenção



Dois modelos foram usados nessa atividade, uma rede neural convolucional treinada do dataset FER2013 com quase 6 milhões de parâmetros e 5 blocos principais de convolução, e o detector de rosto Haar cascade criado por Rainer Lienhart que usa características como bordas linhas e contraste pra identificar rosto nas imagens e que foi o mesmo usado no card anterior do contador de dedos.



A parte teórica que mais ficou foi entender o pipeline completo de uma CNN que começa com o operador de convolução que aplica filtros na imagem e gera os mapas de características focando apenas nas partes mais relevantes, depois vem o Pooling que no caso foi o MaxPooling pegando o maior valor de cada região pra reduzir a dimensionalidade mantendo as informações mais importantes e por último o flattening que transforma tudo isso num vetor que entra na rede neural de fato, esse fluxo todo faz muito sentido quando você vê na prática porque cada etapa vai simplificando a informação sem perder o que importa.

Também foi bem interessante entender as funções de ativação porque cada uma tem uma característica diferente, a RELU retorna zero pra entrada negativas e o próprio valor pra entradas positivas sendo a mais usada no meio das camadas, a Sigmoid mapeia tudo entre 0 e 1 sendo útil pra probabilidade mas com problema do desvanecimento do gradiente em redes

profundas, e a softmax que foi usada na camada de saída convertendo os valores em distribuição de probabilidade entre as 7 emoções possíveis que são Raiva, Nojo, Medo, Feliz, Triste, Surpresa e neutro.

Na parte prática desenvolvi três códigos, o primeiro foi pra testar o modelo em imagens estáticas usando o Haar Cascade pra detectar o rosto e a CNN pra classificar a emoção. O segundo foi onde montei a arquitetura da CNN do zero com camadas de convolução, batch normalization, dropout e maxpooling compilando com otimizador Adam e categorical crossentropy como função de perda que é a indicada pra problema multiclasse como esse

A parte que eu mais gostei foi a detecção em vídeos porque é onde tudo fica mais visual e interessante. Carreguei um vídeo, processei frame a frame e adicionei um threshold de 50% que só desenha o rosto e a emoção quando o modelo estivesse seguro o suficiente, o que reduziu bastante os falsos positivos. Também fiz o redimensionamento automático do vídeo pra não travar o processamento caso a resolução fosse muito grande. Outra coisa que adicionei foi exibir o tempo de processamento por frame na tela, o que foi útil pra acompanhar o desempenho em tempo real no total foram processados 853 frames e o resultado foi salvo num novo arquivo mp4.

Uma limitação que percebi foi que o Haar Cascade tem dificuldade com rostos muito inclinados ou de lado, o que faz o detector perder alguns rostos em cenas de movimento mais brusco, e eu tentar ler algumas faces que não era humanas no caso as de majoras mask e eu tive q abandonar porque eu tava mais usando as cores do personagens do que as expressões deles em si.

3 - Conclusão

Esse card foi um dos mais completos até agora porque juntou teoria e prática de uma forma bem conectada, entender o pipeline da CNN e depois ver ele funcionando numa detecção de emoções em vídeo deixou tudo muito mais concreto. O que mais ficou foi a importância do threshold de confiança porque sem ele o modelo ficava marcando emoções em qualquer coisa e com ele os resultados ficaram muito mais limpos e confiáveis, além disso os conceitos de backpropagation gradiente e funções de ativação que pareciam abstratos ficaram bem mais claros quando você vê eles sendo aplicados num problema real

4 - Referências

Vídeo do card: 23 - Prática: Reconhecimento de Emoções com TensorFlow 2.0 e Python (III)

Documentações usadas:

- <https://docs.opencv.org/4.x/>
- https://www.tensorflow.org/api_docs
- https://www.tensorflow.org/api_docs/python/tf/all_symbols