

Proposta de Projeto Final

Bootcamp de Aprendizado de

Máquina - Lamia

Título do Projeto:	Sistema de Recomendação Inteligente de Jogos para Plataformas
Nome do(a) Aluno(a):	Ronny Gabryel Colatino de Souza
Data da Proposta:	25/05/2026



Definição Detalhada:	O crescimento acelerado do mercado de jogos digitais resultou em catálogos de proporções expressivas. A plataforma Steam, maior distribuidora de jogos para PC do mundo, conta atualmente com dezenas de milhares de títulos disponíveis. Esse volume excessivo de opções configura o fenômeno, no qual o usuário, diante de um catálogo excessivamente amplo, encontra dificuldade em identificar conteúdos alinhados às suas preferências, comprometendo sua experiência dentro da plataforma. Este projeto foi motivado pela observação direta desse problema no cotidiano do usuário e pela relevância que ele representa para o mercado de entretenimento digital. A proposta consiste em transformar os dados implícitos de comportamento do usuário especificamente o tempo dedicado a cada jogo em um sinal mensurável de engajamento, capaz de alimentar um sistema de recomendação personalizado. Do ponto de vista de negócio, um sistema dessa natureza contribui diretamente para a retenção do usuário e para o aumento do consumo dentro da plataforma.
-----------------------------	--

Dados

Fonte dos Dados:	Os dados utilizados neste projeto foram obtidos a partir do dataset público denominado Steam Video Games Dataset, disponibilizado na plataforma Kaggle pelo usuário Tamber. Link para o acesso: https://www.kaggle.com/datasets/tamber/steam-video-games
Informações dos Dados:	O dataset bruto é composto por 200.000 registros de interações de usuários reais da plataforma Steam, estruturados em cinco colunas: user_id (identificador do usuário), game_title (título do jogo), behavior (tipo de interação: compra ou jogo), hours_played (horas registradas na interação) e resto (coluna auxiliar sem valor analítico). O pré-processamento da base envolverá três etapas sequenciais. Na primeira, serão isolados exclusivamente os registros com behavior = play, descartando as entradas de compra, cujo campo hours_played assume o valor padrão de 1.0 e não representa engajamento efetivo com o título. Na segunda etapa, serão aplicados filtros de esparsidade mantendo apenas os usuários com histórico mínimo de cinco jogos e os títulos com ao menos dez interações registradas, critérios necessários para garantir densidade suficiente de informação para o treinamento do modelo. Estima-se que após o pré-processamento a base seja reduzida para aproximadamente 50.000 registros válidos, contemplando em torno de 2.400 usuários únicos e 1.000 títulos distintos. Na terceira etapa, será construída a métrica de engajamento por normalização percentil, descrita em detalhe na seção de

	Metodologia.
--	--------------

Metodologia

Domínio:	O projeto situa-se no Sistemas de Recomendação, mais especificamente na abordagem de filtragem colaborativa. Diferentemente de modelos de classificação supervisionada, que predizem um rótulo fixo a partir de atributos individuais, a filtragem colaborativa identifica padrões de similaridade entre usuários para inferir preferências não observadas, gerando como saída uma lista personalizada de recomendações.
Arquitetura(s):	O algoritmo principal adotado vai ser o SVD (Singular Value Decomposition), implementado por meio da biblioteca Surprise. A escolha dessa arquitetura fundamenta-se em sua capacidade de operar por fatoração de matrizes, decompondo a matriz usuário-jogo em representações de menor dimensionalidade denominadas fatores latentes. Esses fatores capturam padrões implícitos de preferência que não estão explicitamente representados nos dados brutos. Essa abordagem é particularmente adequada ao presente problema, dado que a matriz usuário-jogo apresentará esparsidade estimada superior a 90%, condição em que métodos baseados em similaridade direta perdem eficácia por ausência de sobreposição suficiente entre os perfis dos usuários. Como modelo de referência para fins de comparação, será também treinado um KNN Baseline, que combina estimativas

	de individuais com a medidas de similaridade entre usuários calculadas via correlação de Pearson. A inclusão desse modelo permitirá avaliar objetivamente o ganho proporcionado pela fatoração matricial do SVD em relação a uma abordagem mais simples e interpretável.
Métricas de Avaliação:	O desempenho preditivo dos modelos será avaliado por meio do RMSE (Root Mean Squared Error) e do MAE (Mean Absolute Error), métricas que quantificam o erro médio entre as notas de engajamento previstas pelo modelo e as notas reais observadas nos dados de teste. A robustez do SVD será adicionalmente verificada por validação cruzada com 5 folds, procedimento que avalia o modelo em cinco partições distintas dos dados, reduzindo o risco de que os resultados reportados sejam dependentes de um split específico. A qualidade prática das listas de recomendação geradas será mensurada pelo Hit Rate@10, métrica que calcula a proporção de usuários para os quais ao menos um item genuinamente relevante definido como engajamento real maior ou igual a 3 aparece entre as 10 primeiras recomendações produzidas pelo modelo.
Ferramentas e Bibliotecas:	Para a manipulação e análise dos dados serão utilizadas as bibliotecas Pandas e NumPy. Para a construção das visualizações e análise exploratória, Matplotlib e Seaborn. Para a implementação dos algoritmos de recomendação, validação cruzada e avaliação das métricas de erro, a biblioteca Surprise, com suporte do Scikit-Learn em métricas auxiliares. O ambiente de desenvolvimento adotado será o PyCharm com gerenciamento de dependências via Anaconda.

Possíveis Problemas:	Principal desafio previsto é a esparsidade extrema da matriz usuário-jogo, estimada em torno de 90% após o pré-processamento. Em matrizes com esse nível de esparsidade, algoritmos baseados em similaridade direta entre usuários tendem a produzir estimativas instáveis por ausência de sobreposição suficiente entre os perfis.
	A estratégia que irei adotada para mitigação consistirá na aplicação de filtros de esparsidade no início do pipeline, removendo usuários com menos de cinco interações e títulos com menos de dez avaliações, o que proporcionará maior estabilidade ao treinamento do SVD.

Métricas a serem atingidas:	Para a etapa de validação cruzada com 5 folds, espera-se que o SVD demonstre estabilidade consistente entre as partições, com desvio padrão inferior a 0,005 tanto no RMSE quanto no MAE, indicando que o modelo generaliza adequadamente para observações não vistas durante o treinamento. Para a avaliação da qualidade prática das listas de recomendação geradas, a meta estabelecida para o Hit Rate@10 é de pelo menos 80%, indicando que ao menos 8 em cada 10 usuários deverão receber ao menos uma recomendação genuinamente relevante entre as 10 primeiras sugestões produzidas pelo modelo.
	fonte nos formatos .py estruturado com comentarios

	explicativos em cada etapa, desde a análise exploratória até a avaliação final dos modelos. Serão também disponibilizados o arquivo do modelo treinado, e um arquivo README.md detalhado com as instruções necessárias para que qualquer usuário possa clonar o repositório e executar a aplicação em seu ambiente local, e as documentações.
--	---

Justificativa

O presente projeto demonstra relevância técnica e aplicabilidade prática ao endereçar diretamente um dos problemas centrais do mercado digital de entretenimento a sobrecarga de informação em plataformas com catálogos extensos e a consequente dificuldade do usuário em identificar conteúdos alinhados ao seu perfil de consumo.

Do ponto de vista metodológico, o trabalho vai além da aplicação direta de algoritmos consolidados, enfrentando desafios reais de engenharia de dados. A esparsidade extrema estimada da matriz e a ausência de avaliações explícitas no dataset exigem decisões técnicas fundamentadas: a adoção do SVD por fatoração matricial como estratégia para lidar com a esparsidade, e a construção de uma métrica de engajamento por normalização percentil por título como solução para a ausência de notas diretas dos usuários. Ambas as decisões são teoricamente justificadas e serão empiricamente validadas pelos resultados obtidos ao longo do desenvolvimento.

Fluxograma do Projeto

