

Proposta de Projeto Final

Bootcamp de Aprendizado de

Máquina - Lamia

Título do Projeto:	Sistema de Recomendação Inteligente de Jogos para Plataformas Digitais
Nome do(a) Aluno(a):	Ronny Gabryel Colatino de Souza
Data da Proposta:	25/05/2026



Dados

Definição Detalhada:

[Qual é o problema real ou o cenário que está sendo abordado? Por que escolheu esse problema? Por que é relevante?]]

Se você entrar na Steam hoje, vai ver que tem dezenas de milhares de jogos no catálogo. O problema é que essa quantidade absurda de opções deixa o jogador perdido, gastando mais tempo rodando a página para achar algo do que jogando de verdade. Eu escolhi esse problema pois é algo que tenho contato diariamente e que realmente me incomoda. Ele é relevante porque, vou pegar e transformar o tempo que o cara passa jogando em uma recomendação de mercado

Fonte dos Dados:

[Descreva de onde virão os dados, ex: datasets públicos como Kaggle, UCI ML Repository, APIs como Google Datasets, ou dados sintéticos gerados. Inclua links se possível.]

Os dados que vou usar no projeto vêm de um dataset público chamado Steam Video Games Dataset, que encontrei na

	plataforma do Kaggle. O link de onde achei: https://www.kaggle.com/datasets/tamber/steam-video-games
Informações dos Dados:	[Tamanho aproximado do dataset (número de amostras, features), tipos de dados (numéricos, categóricos, imagens, texto), e qualquer pré-processamento inicial planejado (ex: limpeza de missing values, normalização).] Essa base é bem grande, tem por volta de 200.000 registros de interações de usuários reais da Steam. Ela é bem direta e tem basicamente 4 colunas para trabalhar Use_ID, Game_Title, Behavior e Hours_played. Para o pré-processamento inicial, meu plano é dar uma limpada na base para tirar contas de bots ou so pefils supeitos com milhares de jogos com nenhuma hora ou tempos de jogo impossíveis para alguém assim ficando mais facil de recomendar algo pois. Também vou ter que filtrar a esparsidade dos dados, mantendo os usuários que jogaram pelo menos 5 jogos e os títulos que têm mais de 10 interações, para a tabela não ficar vazia demais, depois como o dataset não traz uma nota explícita de 1 a 5 estrelas feita pelo usuário, vou fazer uma para transformar as horas jogadas em uma escala de engajamento de 1 a 5.

Metodologia

Domínio:	[O problema será de predição, classificação, visão computacional, etc..] O projeto se encaixa na área de Sistemas de Recomendação. Em vez de prever um rótulo fixo de classificação ou só um
-----------------	--

	número isolado, o objetivo aqui é cruzar os dados de vários usuários para sugerir uma lista personalizada no caso jogos.
Arquitetura(s):	[Qual o tipo de arquitetura que será usada? (ex: Redes Neurais, XGBoost) e a justificativa] Vou usar o algoritmo SVD biblioteca Surprise. Escolhi essa arquitetura porque ela trabalha com fatoração de matrizes, que é a melhor forma de resolver o problema de tabelas gigantes cheias de espaços vazios, conseguindo prever o interesse de um usuário por um jogo baseado no perfil de outros jogadores parecidos. Para ter uma base de comparação nos primeiros testes, também pretendo rodar um modelo simples como o KNN Baseline
Métricas de Avaliação:	[Quais métricas serão usadas para medir o desempenho e o sucesso do seu modelo? e justificativa] Como o foco do algoritmo é tentar adivinhar a nota ou o nível de interesse oculto do usuário, vou avaliar o erro das previsões utilizando o RMSE e o MAE, a ideia é deixar esse erro o menor possível. Para medir se a lista final de recomendações faz sentido na prática, também vou usar a métrica Hit Rate@10 , avaliando se o que foi gerado realmente tem a ver com o jogador.
Ferramentas e Bibliotecas:	[Liste as principais ferramentas e bibliotecas que pretende usar] Para a parte de análise e manipulação dos dados, vou de Pandas e NumPy. Para plotar os gráficos e entender o comportamento da base, pretendo usar Matplotlib e Seaborn. Na modelagem e nos algoritmos de recomendação propriamente ditos, a biblioteca principal vai ser a Surprise,

	junto com o Scikit-Learn para dar apoio em algumas métricas
Possíveis Problemas:	[Liste possíveis problemas, ex: Dados desbalanceados.] O principal problema provavelmente vai ser a esparsidade extrema, já que a maioria dos usuários jogou uma quantidade muito pequena do catálogo total da Steam, deixando a matriz cheia de zeros.
	[Como pretende lidar com eles?] Vou aplicando filtros logo no início do tratamento dos dados, removendo da análise aqueles usuários que interagiram com pouquíssimos jogos e descartando títulos que quase ninguém jogou. Isso dá uma enxugada na base e deixa o treinamento do SVD muito mais estável.

Resultados Esperados

Métricas a serem atingidas:	[Defina critérios quantitativos, ex: Acurácia > 95%] A meta quantitativa para o modelo SVD é alcançar um RMSE inferior a 0.85 e um MAE menor que 0.50 na predição de engajamento do usuário. Além disso, para a lista final de recomendações, o objetivo é atingir uma precisão maior que 75%.
Saídas do Projeto	[O que será entregue, ex: modelo treinado, relatório, dashboard em Streamlit, código no GitHub.] Vou entregar o projeto com o ciclo completo de desenvolvimento. A entrega principal vai ser o repositório

	organizado no GitHub contendo o código-fonte em formato de ipynb, bem estruturado e com comentários explicando cada etapa, desde a análise exploratória até a avaliação final. Também vou disponibilizar o arquivo do modelo treinado .pkl ou o formato gerado pela biblioteca e um arquivo README.md detalhado com as instruções para qualquer usuário conseguir clonar e rodar a aplicação na máquina dela.
--	--

Justificativa

[Justifique e defenda o “Porque seu projeto é válido e deve ser aprovado nessa etapa?”]

Meu projeto é totalmente válido e deve ser aprovado porque ele mexe direto com uma das maiores problemas do mercado digital de jogos, que é a retenção e o consumo do usuário dentro da plataforma. Em vez de usar aquela receita de bolo de aplicar algoritmos básicos de classificação tabular em datasets genéricos, decidi encarar um desafio real de engenharia de dados.

O projeto me força a botar a mão na massa para resolver problemas complexos como aquelas tabelas gigantes cheias de espaços vazios e a transformar dados implícitos que é o tempo que o usuário passa jogando em uma métrica real de engajamento para alimentar o modelo. No final das contas, o trabalho entrega um pipeline completo, robusto e que gera valor de verdade para qualquer negócio baseado em recomendação, mostrando que consegui aplicar os conceitos do bootcamp em um cenário prático de mercado.

Fluxograma do Projeto

[Elabore um fluxograma inicial apresentando todas as etapas do seu projeto]

