

# Proposta de Projeto Final

## Bootcamp de Aprendizado de

## Máquina - Lamia

|                             |                                                               |
|-----------------------------|---------------------------------------------------------------|
| <b>Título do Projeto:</b>   | Sistema de Recomendação Inteligente de Jogos para Plataformas |
| <b>Nome do(a) Aluno(a):</b> | Ronny Gabryel Colatino de Souza                               |
| <b>Data da Proposta:</b>    | 25/05/2026                                                    |



|                             |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                      |
|-----------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Definição Detalhada:</b> | <p>O crescimento acelerado do mercado de jogos digitais resultou em catálogos de proporções expressivas. A plataforma Steam, maior distribuidora de jogos para PC do mundo, conta atualmente com dezenas de milhares de títulos disponíveis. Esse volume excessivo de opções configura o fenômeno, no qual o usuário, diante de um catálogo excessivamente amplo, encontra dificuldade em identificar conteúdos alinhados às suas preferências, comprometendo sua experiência dentro da plataforma.</p> <p>Este projeto foi motivado pela observação direta desse problema no cotidiano do usuário e pela relevância que ele representa para o mercado de entretenimento digital. A proposta consiste em transformar os dados implícitos de comportamento do usuário especificamente o tempo dedicado a cada jogo em um sinal mensurável de engajamento, capaz de alimentar um sistema de recomendação personalizado. Do ponto de vista de negócio, um sistema dessa natureza contribui diretamente para a retenção do usuário e para o aumento do consumo dentro da plataforma.</p> |
|-----------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|

# Dados

|                               |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                        |
|-------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Fonte dos Dados:</b>       | <p>Os dados utilizados neste projeto foram obtidos a partir do dataset público denominado Steam Video Games Dataset, disponibilizado na plataforma Kaggle pelo usuário Tamber.</p> <p>Link para o acesso:</p> <p><a href="https://www.kaggle.com/datasets/tamber/steam-video-games">https://www.kaggle.com/datasets/tamber/steam-video-games</a></p>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                   |
| <b>Informações dos Dados:</b> | <p>O dataset bruto é composto por 200.000 registros de interações de usuários reais da plataforma Steam, estruturados em cinco colunas: user_id (identificador do usuário), game_title (título do jogo), behavior (tipo de interação: compra ou jogo), hours_played (horas registradas na interação) e resto (coluna auxiliar sem valor analítico).</p> <p>O pré-processamento da base envolverá três etapas sequenciais. Na primeira, serão isolados exclusivamente os registros com behavior = play, descartando as entradas de compra, cujo campo hours_played assume o valor padrão de 1.0 e não representa engajamento efetivo com o título. Na segunda etapa, serão aplicados filtros de esparsidade mantendo apenas os usuários com histórico mínimo de cinco jogos e os títulos com ao menos dez interações registradas, critérios necessários para garantir densidade suficiente de informação para o treinamento do modelo. Estima-se que após o pré-processamento a base seja reduzida para aproximadamente 50.000 registros válidos, contemplando em torno de 2.400 usuários únicos e 1.000 títulos distintos. Na terceira etapa, será construída a métrica de engajamento por normalização percentil, descrita em detalhe na seção de</p> |

|  |              |
|--|--------------|
|  | Metodologia. |
|--|--------------|

## Metodologia

|                        |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                   |
|------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Domínio:</b>        | <p>O projeto situa-se no Sistemas de Recomendação, mais especificamente na abordagem de filtragem colaborativa. Diferentemente de modelos de classificação supervisionada, que predizem um rótulo fixo a partir de atributos individuais, a filtragem colaborativa identifica padrões de similaridade entre usuários para inferir preferências não observadas, gerando como saída uma lista personalizada de recomendações.</p>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                   |
| <b>Arquitetura(s):</b> | <p>O algoritmo principal adotado vai ser o SVD (Singular Value Decomposition), implementado por meio da biblioteca Surprise. A escolha dessa arquitetura fundamenta-se em sua capacidade de operar por fatoração de matrizes, decompondo a matriz usuário-jogo em representações de menor dimensionalidade denominadas fatores latentes. Esses fatores capturam padrões implícitos de preferência que não estão explicitamente representados nos dados brutos. Essa abordagem é particularmente adequada ao presente problema, dado que a matriz usuário-jogo apresentará esparsidade. Essa abordagem é particularmente adequada ao presente problema, dado que a matriz usuário-jogo apresentou esparsidade de 97,94%, condição em que métodos baseados em similaridade direta perdem eficácia por ausência de sobreposição suficiente entre os perfis dos usuários.</p> <p>Como modelo de referência para fins de comparação, será também treinado um KNN Baseline, que combina estimativas</p> |

|                                   |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                              |
|-----------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|                                   | <p>de individuais com as medidas de similaridade entre usuários calculadas via correlação de Pearson. A inclusão desse modelo permitirá avaliar objetivamente o ganho proporcionado pela fatoração matricial do SVD em relação a uma abordagem mais simples e interpretável.</p>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |
| <b>Métricas de Avaliação:</b>     | <p>O desempenho preditivo dos modelos será avaliado por meio do RMSE (Root Mean Squared Error) e do MAE (Mean Absolute Error), métricas que quantificam o erro médio entre as notas de engajamento previstas pelo modelo e as notas reais observadas nos dados de teste. A robustez do SVD será adicionalmente verificada por validação cruzada com 5 folds, procedimento que avalia o modelo em cinco partições distintas dos dados, reduzindo o risco de que os resultados reportados sejam dependentes de um split específico.</p> <p>A qualidade prática das listas de recomendação geradas será mensurada pelo Hit Rate@10, métrica que calcula a proporção de usuários para os quais ao menos um item genuinamente relevante definido como engajamento real maior ou igual a 3 aparece entre as 10 primeiras recomendações produzidas pelo modelo.</p> |
| <b>Ferramentas e Bibliotecas:</b> | <p>Para a manipulação e análise dos dados serão utilizadas as bibliotecas Pandas e NumPy. Para a construção das visualizações e análise exploratória, Matplotlib e Seaborn. Para a implementação dos algoritmos de recomendação, validação cruzada e avaliação das métricas de erro, a biblioteca Surprise, com suporte do Scikit-Learn em métricas auxiliares. O ambiente de desenvolvimento adotado será o PyCharm com gerenciamento de dependências via Anaconda.</p>                                                                                                                                                                                                                                                                                                                                                                                     |

|                             |                                                                                                                                                                                                                                                                                                                                                                                      |
|-----------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Possíveis Problemas:</b> | O principal desafio verificado foi a esparsidade extrema da matriz usuário-jogo, que pode atingiu 97,94% após o pré-processamento, valor superior à estimativa inicial de 90%. Em matrizes com esse nível de esparsidade, algoritmos baseados em similaridade direta entre usuários tendem a produzir estimativas instáveis por ausência de sobreposição suficiente entre os perfis. |
|                             | A estratégia que irei adotada para mitigação consistirá na aplicação de filtros de esparsidade no início do pipeline, removendo usuários com menos de cinco interações e títulos com menos de dez avaliações, o que proporcionará maior estabilidade ao treinamento do SVD.                                                                                                          |

|                                    |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                 |
|------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Métricas a serem atingidas:</b> | <p>Para a etapa de validação cruzada com 5 folds, espera-se que o SVD demonstre estabilidade consistente entre as partições, com desvio padrão inferior a 0,005 tanto no RMSE quanto no MAE, indicando que o modelo generaliza adequadamente para observações não vistas durante o treinamento.</p> <p>Para a avaliação da qualidade prática das listas de recomendação geradas, a meta estabelecida para o Hit Rate@10 é de pelo menos 15%, valor calibrado com base na esparsidade real de 97% a 90% observada na matriz usuário-jogo. Nesse cenário, atingir essa proporção indica que o modelo consegue entregar ao menos uma recomendação genuinamente relevante para a maioria dos usuários avaliados</p> |
|------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|

## Resultados Esperados

|                          |                                                                                                                                                                        |
|--------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Saídas do Projeto</b> | O projeto será entregue com o ciclo completo de desenvolvimento documentado. A entrega principal consistirá em um repositório organizado no GitHub, contendo o código- |
|--------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------|

|  |                                                                                                                                                                                                                                                                                                                                                                                                         |
|--|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|  | <p>fonte nos formatos .py estruturado com comentários explicativos em cada etapa, desde a análise exploratória até a avaliação final dos modelos. Serão também disponibilizados o arquivo do modelo treinado, e um arquivo README.md detalhado com as instruções necessárias para que qualquer usuário possa clonar o repositório e executar a aplicação em seu ambiente local, e as documentações.</p> |
|--|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|

## Justificativa

O presente projeto demonstra relevância técnica e aplicabilidade prática ao endereçar diretamente um dos problemas centrais do mercado digital de entretenimento a sobrecarga de informação em plataformas com catálogos extensos e a consequente dificuldade do usuário em identificar conteúdos alinhados ao seu perfil de consumo.

Do ponto de vista metodológico, o trabalho vai além da aplicação direta de algoritmos consolidados, enfrentando desafios reais de engenharia de dados. A esparsidade extrema estimada da matriz e a ausência de avaliações explícitas no dataset exigem decisões técnicas fundamentadas: a adoção do SVD por fatoração matricial como estratégia para lidar com a esparsidade, e a construção de uma métrica de engajamento por normalização percentil por título como solução para a ausência de notas diretas dos usuários. Ambas as decisões são teoricamente justificadas e serão empiricamente validadas pelos resultados obtidos ao longo do desenvolvimento.

## Fluxograma do Projeto

